Демонстрація до завдання № 1

Класифікація звуків: міські звуки (UrbanSound8K) та музичні жанри (GTZAN)

Цей ноутбук — приклад для показу на парі. Розв'язуємо обидві частини завдання за допомогою **CNN** (Convolutional Neural Network — згорткова нейронна мережа):

1. **UrbanSound8K** — 8732 короткі (до 4 с) записи міських звуків 10 класів: кондиціонер, автомобільний сигнал, дитячі ігри, гавкіт собаки, дриль, двигун на холостому ходу, постріл, відбійний молоток, сирена, вулична музика.
2. Навчання мережі, порівняння кількох варіантів параметрів.
3. Перевірка на «власних» записах (тут — вільні записи сирени, гавкоту, автомобільного сигналу та відбійного молотка з Wikimedia Commons; студенти записують справжні звуки телефоном).
4. **GTZAN** (колекція Джорджа Цанетакіса, проєкт Marsyas) — 1000 тридцятисекундних музичних фрагментів 10 жанрів; та сама ідея CNN, застосована до класифікації жанрів.

Ключова ідея: звук перетворюємо на **log-mel спектрограму** — «картинку», де по горизонталі час, по вертикалі частота (у mel-шкалі, наближеній до сприйняття людським вухом), а яскравість — енергія в децибелах. Далі з нею працює звичайна згорткова мережа, як із зображенням.

```
Пристрій для навчання: mps (MPS = Metal Performance Shaders, GPU Apple Sil
icon)
```

1. Завантаження UrbanSound8K

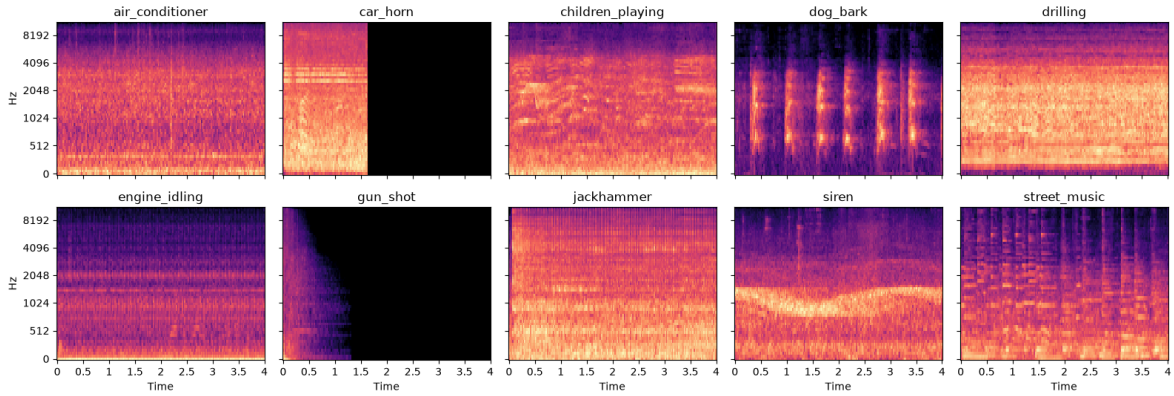
Беремо копію оригінального датасету з Hugging Face Hub (`danavery/urbansound8K`, ~7 ГБ у форматі Parquet). Аудіо там те саме, що й в оригіналі; разом із кожним записом зберігається номер **fold** (одна з 10 заздалегідь заданих частин датасету). Автори UrbanSound8K наголошують: ділити дані потрібно саме по fold-ах, бо фрагменти одного й того самого запису лежать в одному fold-і, і випадкове перемішування дає завищену точність.

Розбиття: fold 1–7 — навчання, fold 8 — валідація (вибір найкращої епохи), fold 9–10 — тест.

```
Спектрограми: (8732, 64, 173) (кліпи x mel-смуги x часові кадри), 1 с
  0. air_conditioner    1000
  1. car_horn            429
  2. children_playing   1000
  3. dog_bark           1000
  4. drilling           1000
  5. engine_idling      1000
  6. gun_shot            374
  7. jackhammer         1000
  8. siren               929
  9. street_music       1000
```

Як виглядають класи на log-mel спектрограмах

Видно, що класи відрізняються «текстурою»: сирена — плавні дуги (тон, що змінюється), відбійний молоток і дриль — вертикальні смуги (періодичні удари), кондиціонер і двигун — рівномірний низькочастотний шум, постріл — один короткий широкосмуговий імпульс. Саме такі локальні візерунки й шукають згорткові фільтри CNN.



2. Модель CNN та навчання

Архітектура — 4 згорткові блоки «згортка 3×3 → **BN** (Batch Normalization, нормалізація по міні-батчу) → **ReLU** (Rectified Linear Unit, max(0, x)) → MaxPool 2×2», далі глобальне усереднення (Global Average Pooling), Dropout і повнозв'язний шар на 10 класів.

Навчання: оптимізатор **AdamW** (Adam з окремим weight decay — L2-регуляризацією ваг), розклад швидкості навчання **OneCycle** (спочатку зростає, потім плавно спадає — стабільніше за сталий learning rate), 30 епох, батч 64. Після кожної епохи міряємо точність на валідації (fold 8) і зберігаємо найкращу модель.

SpecAugment — аугментація спектрограм: на кожному кроці навчання випадково «затираємо» смугу частот і проміжок часу, щоб мережа не запам'ятовувала окремі деталі.

```
train: 6273  val: 806  test: 1653
Параметрів у базовій моделі: 98922
```

Експерименти з параметрами (пункт 3 завдання)

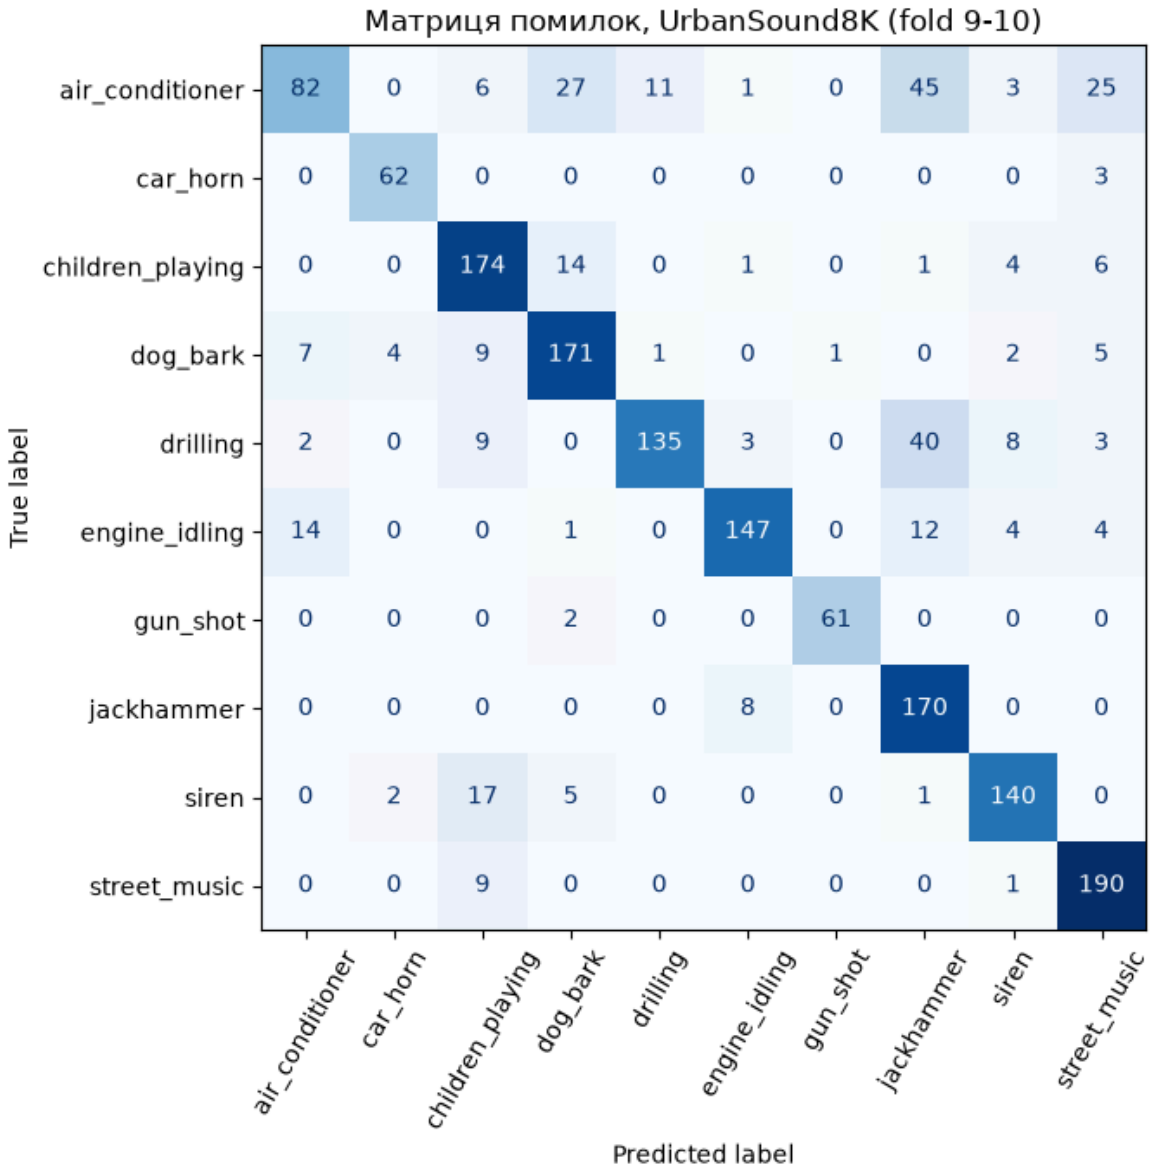
Порівнюємо чотири варіанти: базова модель; + SpecAugment; ширша мережа (удвічі більше фільтрів); менша швидкість навчання. Метрики на тестових fold-ах 9–10: accuracy (частка правильних відповідей) та macro-**F1** (середнє гармонійне precision і recall, усереднене по класах — чесніше за accuracy, коли класи нерівні за розміром).

```
A. базова (16–128 фільтрів, lr=2e-3)     test acc=0.806  macro-F1=0.821
(95 с)
B. + SpecAugment                         test acc=0.748  macro-F1=0.773
(91 с)
C. + SpecAugment, ширша (32–256)         test acc=0.816  macro-F1=0.833
(147 с)
D. + SpecAugment, lr=5e-4                test acc=0.751  macro-F1=0.759
(92 с)
```




```
Найкращий за валідацією варіант: A. базова (16–128 фільтрів, lr=2e-3) (val
acc = 0.764)
```

	precision	recall	f1-score	support
air_conditioner	0.781	0.410	0.538	200
car_horn	0.912	0.954	0.932	65
children_playing	0.777	0.870	0.821	200
dog_bark	0.777	0.855	0.814	200
drilling	0.918	0.675	0.778	200
engine_idling	0.919	0.808	0.860	182
gun_shot	0.984	0.968	0.976	63
jackhammer	0.632	0.955	0.761	178
siren	0.864	0.848	0.856	165
street_music	0.805	0.950	0.872	200
accuracy			0.806	1653
macro avg	0.837	0.829	0.821	1653
weighted avg	0.820	0.806	0.798	1653



Що обговорити: найслабший клас — кондиціонер: рівномірний шум без характерної форми мережа часто приймає за двигун або відбійний молоток; дриль і відбійний молоток також плутаються між собою. Постріл, автомобільний сигнал і двигун на холостому ходу розпізнаються найкраще — у них дуже характерна форма на спектрограмі.

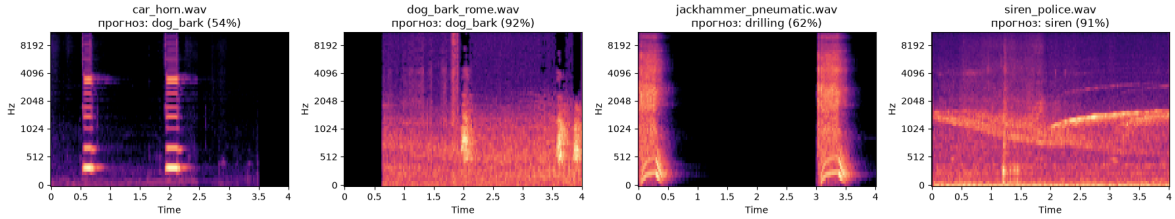
3. Перевірка на власних звуках (пункт 4 завдання)

Студенти записують телефоном 2–3 звуки класів, які є в датасеті (сирена, сигнал авто, гавкіт, вулична музика тощо). Замість власних записів для демонстрації беремо чотири справжні записи з Wikimedia Commons, яких мережа ніколи не бачила (інші мікрофони, інші міста). Вони конвертуються у WAV (моно, 22 050 Гц) через `ffmpeg` — так само варто робити із записами з телефона (M4A/AMR/OGG → WAV).

Функція `predict_file` працює з будь-яким WAV-файлом: довгий запис ріжеться на вікна по 4 с з кроком 2 с, імовірності вікон усереднюються.

```
siren_police.wav            29.2 с   Public domain, автор: lezer
dog_bark_rome.wav           17.7 с   CC BY-SA 3.0, автор: Nicholas Gemini
car_horn.wav                 3.5 с   CC0, автор: 15HPanska_Ruttner_Jan
jackhammer_pneumatic.wav    11.3 с   CC0, автор: ldezem

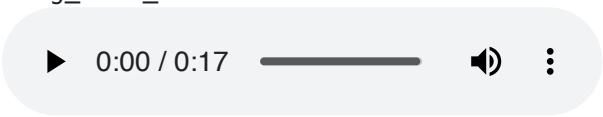
car_horn.wav         -> dog_bark 54%,  children_playing 26%,  street_music
10%
dog_bark_rome.wav    -> dog_bark 92%,  children_playing 7%,  siren 0%
jackhammer_pneumatic.wav -> drilling 62%,  dog_bark 20%,  gun_shot 16%
siren_police.wav     -> siren 91%,  dog_bark 5%,  children_playing 3%
```



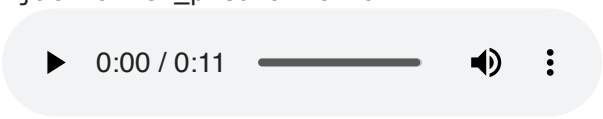
`car_horn.wav`



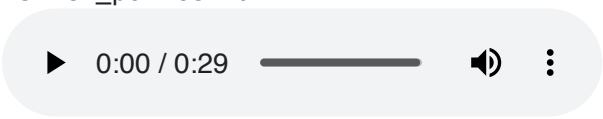
`dog_bark_rome.wav`



`jackhammer_pneumatic.wav`



`siren_police.wav`



Що обговорити: помилки на «чужих» записах — нормальна й важлива частина звіту. Відбійний молоток легко сплутати з дрилем (ці класи плутаються і на тестовому наборі), а одиночний короткий гудок, записаний зблизька, звучить інакше, ніж далекі сигнали машин у UrbanSound8K. Поради для запису: формат WAV (або конвертація з M4A/MP3), моно, без сильного шумозаглушення телефона, тривалість від 4 с. Якщо мережа помиляється — пояснити чому (інший мікрофон, відстань, накладання звуків) і спробувати інший варіант моделі.

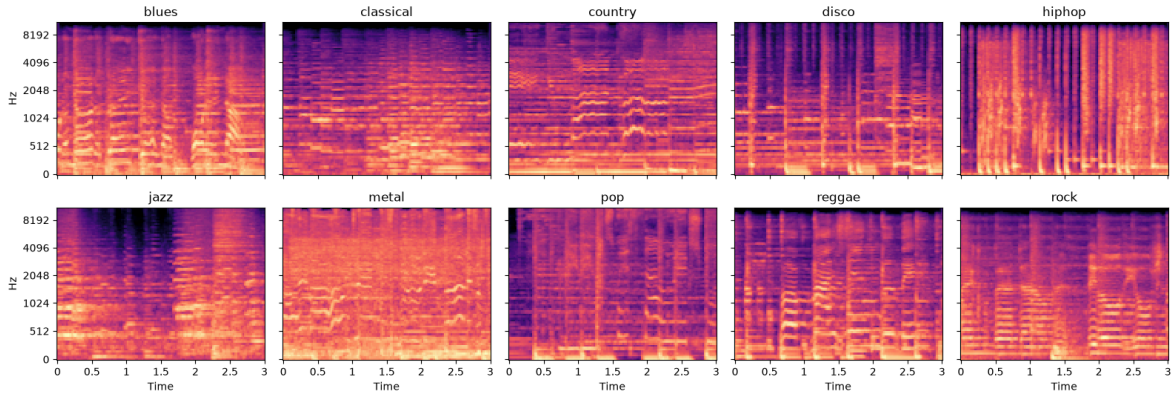
4. Класифікація музичних жанрів, GTZAN (пункт 5 завдання)

GTZAN — 1000 фрагментів по 30 с (22 050 Гц, моно), по 100 на кожен з 10 жанрів: blues, classical, country, disco, hiphop, jazz, metal, pop, reggae, rock. Офіційна копія від проєкту Marsyas — на Hugging Face (`marsyas/gtzan`).

Підхід:

- кожен трек ріжемо на 10 фрагментів по 3 с → ~10 000 спектрограм (96 mel-смуг);
- ділимо на train/test **за треками** (80/20, порівну жанрів), щоб фрагменти одного треку не потрапили одночасно в навчання й тест;
- прогноз для треку — усереднення ймовірностей його 10 фрагментів («голосування»).

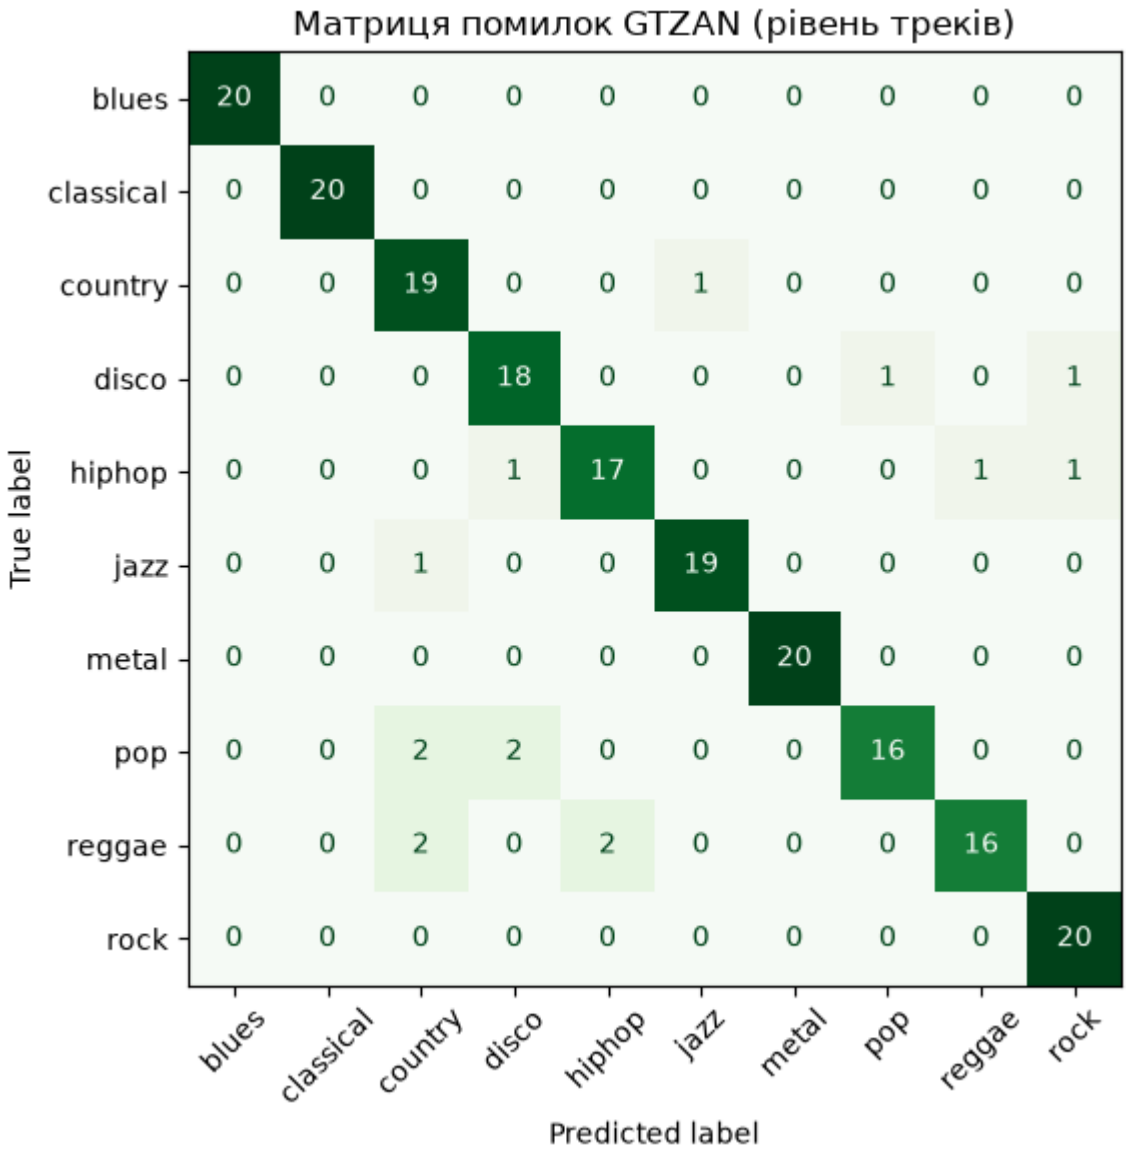
```
Треків: 999, фрагментів по 3 с: (9981, 96, 130), 21 с
Жанри: ['blues', 'classical', 'country', 'disco', 'hiphop', 'jazz', 'meta
l', 'pop', 'reggae', 'rock']
Треки train/val/test: 719/80/200
```




```
A. базова (16–128), без аугментації      фрагменти: 0.815   треки (голосув
ання): 0.885   (115 с)
B. ширша (32–256) + SpecAugment          фрагменти: 0.851   треки (голосув
ання): 0.925   (184 с)

Найкращий за валідацією варіант: B. ширша (32–256) + SpecAugment (val acc
фрагментів = 0.806)
```

	precision	recall	f1-score	support
blues	1.000	1.000	1.000	20
classical	1.000	1.000	1.000	20
country	0.792	0.950	0.864	20
disco	0.857	0.900	0.878	20
hiphop	0.895	0.850	0.872	20
jazz	0.950	0.950	0.950	20
metal	1.000	1.000	1.000	20
pop	0.941	0.800	0.865	20
reggae	0.941	0.800	0.865	20
rock	0.909	1.000	0.952	20
accuracy			0.925	200
macro avg	0.928	0.925	0.925	200
weighted avg	0.928	0.925	0.925	200



Що обговорити:

- голосування фрагментів підвищує точність: окремі 3 секунди можуть бути «нетиповими» для жанру, а 30 секунд — ні;
- classical, blues, metal і jazz розпізнаються майже без помилок; найважчі — pop, reggae, disco і rock: у них схожі ритм і тембр, межі між цими жанрами розмиті навіть для людей;
- відомий недолік GTZAN: багато треків одних і тих самих виконавців, є повтори, тому при випадковому розбитті точність трохи завищена (мережа частково «впізнає виконавця», а не жанр).

5. Що має бути у звіті студента

1. Опис датасетів і способу розбиття на train/val/test.
2. Перетворення звуку на спектрограму (параметри: частота дискретизації, n_fft, hop, кількість mel).
3. Архітектура CNN (таблиця шарів, кількість параметрів).
4. Таблиця експериментів з різними параметрами + криві навчання, висновок, що допомогло.

5. Матриця помилок і аналіз, які класи плутаються та чому.
6. Результати на власних записах (спектрограми, top-3 прогнози, пояснення помилок).
7. Те саме для GTZAN; порівняння точності на рівні фрагментів і треків.